人 × Agent（Aegis 标准）任务产出评估报告

案例：PROCESS V3 — Windows Client / Ubuntu Server 第一阶段软件研发
版本：V1.0 / 2026-11-05
证据截止：2026-11-05 20：40（按任务日志所示时刻；时区未独立验证）
用途：Aegis 落地案例分析、工程管理复盘、后续对照实验设计
证据性质：单案例、非受控对照；含传统工程量情景估算。

执行摘要

结论 1 — 交付效率在工程量级上表现突出。 第一阶段完成了可运行的 Windows 桌面 Client、Linux
rver、独立 Scheduler.Sim、真实可信通信诊断、软件控制与恢复约束，以及多层测试和发布材料。Agent
任务日志累计 43 小时 27 分 03 秒（43.4508 h），跨 6 天 11 小时 11 分（155.183
整生产系统的交付时间。[U1][S1][S2][S3]

结论 2 — 传统人工基线只能做条件估算。 本报告按相同已完成软件范围、相似验收深度建立自下而上的人
工工作分解：400 / 600 / 900 人时（精简 / 中心 / 审慎情景）。对应“传统人工人时 ÷ Agent 任务日
时”的名义工时量级比为 9.2 / 13.8 / 20.7 倍。该数值不是经过对照实验测出的开发加速率，也不是 Ae
gis 相对于裸 Codex 的增益。[M1]

结论 3 — 人类交互投入较低，但真实人工总投入未知。 另一张截图估算对话输入与阅读为 3 小时 15 分
，其计算范围 2 小时 44 分至 4 小时 06 分，且未覆盖独立阅读、架构思考、人工终端操作、环境配置及
实机检查。以 3.25 h 直接相除会出现 123–277 倍的条件人力杠杆，但不能作为实测人效、节省工时或对
外宣传数字。[U2]

结论 4 — 高难度集中在可靠性，而非界面数量。 多身份和独占控制、跨进程三通道通信、原 ID 幂等、任
务与连接生命周期分离、未知结果对账、存储降级和严格恢复隔离，构成主要工作量。UI 只是可见的一个部
分。[S1][S2]

结论 5 — 质量证据有分层，必须保留未完成项。 G3 受限矩阵 48/48 通过；G5 的单站 900 秒与四站
0 秒软件合成负载在最终候选通过；真实 C/S 10 分钟连接无意外断开，但 600 个预定 time 槽漏 1 个
严格结果 INCOMPLETE。主界面仍是 Mock，正式 A–F、生产 Scheduler/SDK、硬件、完整业务
成。该案例证明的是高强度软件阶段的产出能力，不是产线投放能力。[S1][S3]

对 Aegis 落地的判断： 可以作为“高复杂度软件阶段的高产出个案”与后续评估基线；不能单靠它证明 Ae
gis 专属增益、行业平均加速倍数、生产可靠性或商业 ROI。优先补齐个人实际工时、Agent 用量成本以及
与“人工+原生 Codex”相同验收口径的对照数据。

1． 评估对象与相同范围原则

1.1 当前已交付的软件阶段

交付域	本阶段实际完成 / 有证据的能力	当前重要边界
Windows Client	C#/.NET 10/Avalonia、总览/详情、状态隔离、头像
程、Win11 安装候选	主业务 provider 仍为 Mock；当前真实网络通信是独立诊断窗口
Server	Linux/.NET 10/ASP.NET Core、身份/权限、独占接入、审计/
久化、故障和有限恢复	当前 Development/软件模拟范围；没有生产 Scheduler 或硬件控
独立源	Scheduler.Sim、UDS、周期推送、模拟任务/设备/工艺包、查询和原命令去重
无真实 SDK、机器人、.acorn 生产解释器
C/S 实链	实际 Avalonia Client → 已安装 Linux Server 的 T
S/ACK，独立计量	不等于主 UI 业务动作已接 Server；600 秒严格完整性未通过
交付体系	Win11 安装 exe、Ubuntu 双 deb、受限安装升级卸载、无 SDK 验证

材料准备	Win10、签名 / SmartScreen、商用信任材料未完整验收
测试证据	G1–G5 的软件矩阵 / 异常验证、合成负载、真实连接诊断、版本 / 候选 / 失败记录
正式 A–F 仍 STOP；不能用 Mock / Sim 结果外推物理安全	

比较规则： 人工基线只计完成以上软件阶段所需工作。未完成的业务 provider、物理调度器、生产硬件、安全攻防专项、完整非静止灾备、正式 A–F 不能进入人工估算的分子，否则会人为夸大加速比。G4 已明确延期的四项真实异常端到端验证亦不算完成。[S1§15–17][S2§31][S3§14/16]

1.2 系统规模的可观察指标

指标	可观察事实	解释边界
操作系统	Windows 11 Client + Ubuntu 24.04 Server	in10、Linux Client
主运行角色	Client、Server、Scheduler.Sim 三类进程	维护工
是辅助进程，不算已投产业务服务		
主要通信机制	HTTPS、WSS、同机 UDS	三种逻辑链路；传输状态与设备状态不同
工站控制	每站至多一个有效业务控制连接	可选择多个 Server，不代表一站多用户并
发控制		
软件负载	单站 900 s；四站 300 s	有限合成负载；不是最大容量声明
负载基线	每站 2 臂、100 标准字段、2000 详细字段、1000 节点 / 4000 边、50	模拟数据与工程测试规模，不是物理设备部署规模
UI 合成规模	曾检查 100 站展示 / 1000 节点	不等于 100 站生产网络实
状态持久性	SQLite schema 8、请求账本、outbox、审计、恢复隔离	
溃窗均已验		
测试计数	G3 48 个原子项；UI 最终 551 个对象断言等	测试项、断言、消息
不可直接加总		

缺失的规模指标： 净新增生产代码行、复杂度 / 依赖图、准确 commit / PR 数、人工审核差错率、测试去重后的独立用例数、长期缺陷率均未在这三份整合文档与截图中形成可复算的一致统计。因此本报告不以“代码量”估算工程量。[S2][S3]

2. 复杂度分析：难在失败状态的组合

2.1 复杂度来源与影响

维度	相对评价	关键机制与为什么费时
功能广度	中高	多页 UI、账号 / 权限、任务 / 工艺包、历史、日志、安装维护，跨功能
测试面较宽		
架构耦合风险	高	Client / Server / 独立 Scheduler 的职
能伪造源执行结果		
并发与状态空间	很高	独占接入、接替、断连、重启、迟到回执、权限撤销同时发生时
必须维持正确因果		
数据一致性	很高	原 ID 语义、请求与效果分离、outbox 对账、库存严格相等与
门		
故障处置	很高	存储降级、受限原对象结束、unknown 不重做、fault / cle
very 有不同证据		
UI 工程	中	自绘桌面布局、局部滚动、状态隔离、资源边界；主要难点是工程细节而
非渲染研究		
测试验证	很高	独立进程、故障模拟、版本闭包、负载、发布 / 回滚、实际跨机连接及
原始证据保留		

| 物理与生产风险 | 尚未测评 | 真实 Scheduler / SDK / 机械臂、实际停止 / 释放、和生产身份体系未完成；不可给生产质量评分 |

上述定性分级仅为本报告的工程判断，不属于行业统一复杂度量表；它也不意味着每项能力都在最终同一二进制上完成穷举验收。

2.2 为什么同一功能会形成多个困难场景

以“管理员接替正在运行的任务”为例：一站只允许一个控制者；合法新管理员必须先确认，随后原子切换控制代次；旧连接的新输入失效；原任务 / 包 / 参数 / 进度、已接纳但未派发 outbox、审计发起者继续保留；接替本身不得添加 stop、withdraw、recover、query 等源端动作。管理员取消、老连接断开、源返回近 Server 重启等分支必须分别处理。[S1§5][S2§14]

以“响应丢失后的执行请求”为例：HTTP 成功只证明服务器响应，accepted 只证明受理；命令可能已经交给 Scheduler。系统不能重新分配 ID 盲目重发，应按原 ID 和源持久身份核查。当源记录覆盖不足时，正确结果可能一直是 unknown，而不能伪装成功或失败。[S1§9][S2§16]

以“数据库恢复后是否解锁业务”为例：备份文件完整并不证明恢复时源端无新增命令。恢复在 quarantine 状态中核对全命令集合、任务状态、源代次和可信证明；任何不完整或仍活跃对象阻断 finalize。该软件机制的设计 / 验证复杂度高于普通 CRUD 恢复。[S1§11][S2§24]

工程难度的主要驱动： 正常路径代码量有限；每增加一个独立故障源、代际或权限边界，测试组合明显增加。由于没有完整的状态空间枚举，本报告不计算“组合数”等伪精确指标。

3. 传统研发人时：可审计的工作分解估算

3.1 估算假设

- 工程师基线： 有相关经验的 C# / .NET 桌面与 Linux 服务端工程师；可以使用 IDE、调试器、现成框架和普通脚本，不假设完全手写密码学或 HTTP / IPC 底层。
- 相同验收边界： 达到当前“软件阶段已证明”的功能、测试和交付证据；不完成未授权的正式 A–F 与硬件产线验证。
- 单位： 人时是全部人的投入之和，研发、测试、评审、故障修复各算一次；团队并行可减少日历时长，不能自动减少人时。
- 数值性质： 下表是基于已交付功能拆分的低 / 中 / 高情景赋值，并未来自同一项目的人工对照实验或经过校准的生产率数据集；不能把情景跨度解释为统计置信区间。

3.2 工作分解（WBS）

工作包（互不重复口径）	精简 h	中心 h	审慎 h	主要包
需求梳理与变更裁决	25	35	60	需求冲突、权限 / 控制边准；不计后续文档排版
架构设计与协议契约	30	50	75	职责分离、通信 / 状态协审；不含实际编码
Windows Client UI 与 Mock	35	55	90	情 / 头像 / 布局 / 配置；Mock 不算真实业务联调
真实 Client 通信诊断	15	22	35	TLS / HT量与诊断窗口；不含完整业务 provider
Server 身份与控制	45	70	100	身份、独占会话与控制权限；不含恢复存储
Scheduler.Sim / UDS / 遥测	35	50	80	有效性、模拟设备 / 任务；不含物理硬件
幂等、故障与受限恢复	65	95	140	outbox / 原

t / c l e a n u p、备份与恢复隔离 |
功能 / 异常测试及缺陷修复	8 5	1 1 5	1 5 5	G1–G4、例设计、工具、复现、修复和回归；不含负载
跨平台构建与安装交付	2 0	3 6	5 5	W i n 1 1 e x e、K、部署 / 升级 / 卸载有限测试
负载、真实集成与环境验证	2 5	4 0	6 5	9 0 0 / 3 0 0 连接、配置和环境问题定位
证据归档与技术文档	2 0	3 2	4 5	文档整合、结果范围复核索引；不重复记功能测试
合计	4 0 0	6 0 0	9 0 0	与本阶段交付范围对齐的人工情景

估算的主要不确定性来自三项：是否已有可复用的基础通信 / 身份库；工业状态机设计者对幂等 / 恢复的熟悉程度；测试工具和发布环境是否现成。任何一种情景都不能称作“ 行业正常用时 ”或“ 传统平均用时 ”。

3 . 3 传统项目的时间结构

在中心情景 6 0 0 人时 下，若按每人每日 8 小时计算，相当于 7 5 人日。一个人串行执行约 7 5 个工作日；两人理想完全平行约 3 7 . 5 工作日；三人理想完全平行约 2 5 工作日。后两项只是人日除以人数的算术下界，尚未计入依赖、协调和评审阻塞，不能预测真实排期。

对照历史 A I 研究也不能自动获得人工基线。研究测量的是不同工程师、工具、任务和时间窗口下的平均处理变化，不是这个工业 C / S 案例的人工实现总时长。[E 1] [E 2] [E 3]

4 . A e g i s 案例的实际日志与人工交互

4 . 1 A g e n t 任务日志

任务类型	日志显示时间	占 4 3 . 4 5 0 8 h（约）	计入范围
- - -	- - - :	- - - :	- - -
需求文档对齐	3 h 4 8 m i n	8 . 7 %	C l i e n t / S e r v e r 则与复核
实现方案对齐	8 h 4 3 m i n	2 0 . 1 %	技术选型、U I / 通信 / 实
研发	1 7 h 3 3 m i n	4 0 . 4 %	C l i e n t、S e r v e r、S
独立自测及开发期验证	1 2 h 3 1 m i n	2 8 . 8 %	自测与部分 M 验证、集成和复查
最后文档整合与交付审核	5 2 m i n 3 3 s	2 . 0 %	最后三份文档的
日志权威总值	4 3 h 2 7 m i n 0 3 s	1 0 0 %	以截图精确总值

四类工时“ 约到分钟 ”，其显示值相加为 4 2 h 3 5 m i n，和截图标注“ 约 4 2 h 3 4 m i n ”存在约 1 m 入差；再加 5 2 m i n 3 3 s 与精确总值存在数十秒显示差异。本报告只用 4 3 : 2 7 : 0 3 作为比值分母，避免通过舍入值反推精确时间。[U 1]

该日志期间有 9 8 个已完成轮次，起止时间跨度 1 5 5 h 1 1 m i n。是否含并发子 A g e n t 的重叠、工具阻塞等待、T o k e n 计算与用户审核，未见可独立核验的时间定义。4 3 . 4 5 h 不能直接解释为模型计算时长、纯代码编写时长、所有子 A g e n t 工时之和或完整真实交付关键路径。[U 1]

4 . 2 人类交互量与估算的适用范围

另一张统计截图给出：1 2 7 条普通消息、约 6 8 5 7 个非空字符、1 8 次表单回复、回答 1 9 个问题、提供 2 0 张图片；按“ 输入 4 0 – 6 0 字 / 分钟，阅读约 3 0 0 7 1 字、4 0 0 – 6 0 0 字 / 分钟 ”的假设，输入约 1 h n – 2 h 5 1 m i n，阅读约 5 0 m i n – 1 h 1 5 m i n，合计 2 h 4 4 m i n – 4 h 0 6 m i

。[U2]

这个值有两个不同的不确定性：速度假设不确定（实际上可能语音、复制粘贴、跳读或反复读），活动覆盖不完整（图文检查、审查代码 / 测试材料、终端操作、思考、现场沟通不在计数中）。因此不能据此得出用户总工时 = 3.25 h，更不能用它直接计算已验证的人力 ROI。

用户另述 UI 在一个下午完成、其他部分在两个较集中工作日内完成（不计睡眠）。这是工作节奏的自述；与日志总跨度 6 天 11 小时不矛盾，但无法据此复算每一天的人类有效工时。[U1][U2]

5. 产出效率：四种时间 / 资源指标必须区分

5.1 可算，但不能误命名的名义压缩系数

定义：

Rlog = 假定传统研发人时 / Agent 日志任务小时 = B / 43.450833...

传统人工情景 B	Aegis 日志任务时长	Rlog
400 人时	43.4508 h	9.21×
600 人时（中心）	43.4508 h	13.81×
900 人时	43.4508 h	20.71×

解释： 这是“估计人工工作量相对于 Aegis 日志任务时长”的条件比值。分子的单位是人力劳动、分母是平台日志时长，不能直接叫严格交付加速比或 Agent 资源效率。若日志任务时长与真实并发 / 等待结构不一致，压缩系数会变化。[M1]

5.2 人力杠杆的敏感性：真实人工时长尚未实测

定义：Rhuman = B / Htotal，其中 Htotal 必须包含全部人工需求决策、审查、交互、终端 / 实机操常处理和交付验收，而不只包含聊天。

假设实际人类投入 Htotal	400 人时基线	600 人时基线	90
3.25 h（仅截图中心粗估，不能认定为总量）	123.1×	184.6×	
6 h（条件示例）	66.7×	100.0×	150.0×
10 h（条件示例）	40.0×	60.0×	90.0×
15 h（条件示例）	26.7×	40.0×	60.0×
24 h（条件示例）	16.7×	25.0×	37.5×

这张表是敏感性分析，不是对真实劳动产出的五次观测。即使真实人工时间确认，仍需人工对照基线才能给出因果意义上的提升幅度。

5.3 交付速度与经济效率：当前不能给单点倍数

想衡量的指标	正确定义	当前是否可算
名义日志工时量级比	估算人工人时 ÷ 43.4508 h	可作条件演示：9.21–2
人力节省 / 人力杠杆	同范围人工人时 ÷ 实际完整个人 / 团队人时	不可实测：完整人工 H 未采集，基线未对照
交付延迟加速	传统方案到同一验收门的关键路径日历时长 ÷ Aegis 到该门的实际关键路径日历时长	不可实测：传统排期未实测，Agent 任务日志不等关键路径
Agent 计算效率	相同合格产出 ÷ API / 模型调用、Token、运行成本	不可

分 Agent Token、价目、机器资源成本 |
| 净经济收益 | 省下的人工成本 − AI / 计算 / 运维 / 审查与后续缺陷成本 | 不可实测：缺真实人工工时、成本与稳定质量数据 |
| Aegis 专属增益 | “人 + Aegis”对比“同一人 + 直接使用 Codex”的差异 | 因：没有同题对照或消融实验 |

实际跨越 155.1833 h 是可报告的完整时间窗口，但其中有等待、睡眠、暂停和其他工作。它不能作为传统 400–900 人时 的直接分母；否则同时混用了人时与自然时，失去可比性。[U1]

6. 协作机制的额外价值：有工程迹象，暂无独立增量证明

机制	本案例中的可观察迹象	可能形成的收益	需要怎样证实增益
人类做目标 / 约束裁决，Agent 执行	多轮需求冻结 / 更改；98 个完成轮次与较少的人类对话输入	将人的时间从重复实现转向关键判断	完整记录人工审查 / 返工时长，和同任务人工 / 直连 Agent 对照
任务分层与角色独立	开发自测、部分 Master / 独立审核、受限交付判定分列	提升复查覆盖；降低作者自证偏差	比较独立审核发现的新增缺陷、严重度和修复成本
规范 / 因果 / 档案关联	旧 FAIL、候选版本与替代关系、原 ID、证据边界保留	降低轮次上下文重建和错误复用	比较后续接续任务的恢复时间、误判次数及审核消耗
自动化测试与回归	G3 / G4 / G5 多轮软件行为测试，原 FAIL 不删除	缩短复现—修复—验证循环	提取每个 defect 的发现时刻、修复时间、复发与逃逸情况
跨平台部署自动化	Windows / Ubuntu 安装、配置与真实网络诊断均出现自动化证据	减少环境搭建重复劳动	对照人工环境准备时长、部署成功率与故障率
稳定的质量停点	G4 延期、C / S INCOMPLETE、正式 A–F STOP 按原范围保留“可运行”误宣称为“生产验收”	外部审查跟踪漏报、错报和未授权动作数量	

重要归因限制： 上述收益可能同时来自优秀基础模型、Codex Harness、用户的需求裁决、成熟 .NET 生态、Agent 多轮执行和 Aegis 的治理设计。一个全程使用 Aegis 的案例无法把这些因素逐个分离。Aegis 身的约束还有潜在额外消耗：设计审查、证据保存、重复验证、严格拒绝与分支协调。是否值得，要测“降低的缺陷 / 返工成本是否大于这些额外工时与 Token”，不能只看完成轮次。

6.1 交付前质量投入的信号

从日志展示值看，需求 + 方案约 12.52 h（28.8%）、开发期验证约 12.52 h（28.8%），而 编码研发 .55 h（40.4%）。剩余约 2% 为最终文档整合。此结构说明本次不仅做功能代码，还投入大量时间在需求约束和软件验证中。它不能独立证明这些验证成本在未来迭代中能够摊薄；是否摊薄要由后续维护数据确认。[U1]

6.2 质量优先可能带来的后续收益（待追踪假说）

- 若前期严格界定控制权限、请求幂等与恢复门，后续新增业务可以降低“先运行、后补保护”的返工风险。
- 若证据和因果记录可复用，跨 Agent / 跨会话问题定位可能降低上下文重建成本。
- 若测试与生产真实状态存在差距，软件级质量并不能保证现场缺陷率下降；硬件、正式工艺与正式独立测试仍可能带来大幅补工。

这三项均是可检验假说，不计入当前 9.21–20.71× 数值。

7. 已验证产出与质量债务并列登记

领域	证据及判断	不可抹除的缺口
新 G3 控制矩阵	8 组、48 原子项，原范围 PASS；有跨候选限定沿用	不是全

项在最终相同二进制重跑 |
| G4 | 31 字母项目，多个真实故障 / 恢复路径覆盖 | 整体 PARTIAL；真实 OS
nel 满、createdump 成功和诊断工具异常端到端按用户决定延期；旧 FAIL 保留 |
| G5 发布与可靠性 | Win11 / Ubuntu 发行、限定真实安装升级卸载和受限恢复验证 |
止 / 不完整覆盖生产灾备未完成；Win10 延期 |
| G5 性能 | final07 单站 900 s 与四站 300 s PASS | fina
留；高负载裕量有限，非真实设备能力证明 |
| Client UI | 551 对象断言及限定原生检查，UI 状态和滚动等有证据 | 对象断
51 独立场景；DPI / 多屏 / 原生交互没有穷举 |
| 真实 C/S | 同一实际 Avalonia 进程完成 TLS / 身份 / WSS；600.066 s、意
ror 0、timeout 0、sequence gap 0 | time 599/600、snapshot
主业务 Provider 仍 Mock |
| 生产验收 | 已列后续接口与未授权范围 | 正式 A–F STOP；真实 Scheduler
动作和完整业务数据联调未完成 |

证据解释原则： 一个局部 PASS 只证明原候选、原步骤、原阈值；不能抹去旧 FAIL、NOTRUN、ENVBLOC
、PARTIAL 或扩大到生产硬件。提供的三份整合文档本身是对既有原始记录的二级整理，本报告未独立运行
程序、读取所有原始 JSONL 或重审所有 4673 份盘点文件。[S3]

8. 外部研究用于校准解释，不直接校准本项目 400–900 h

2025 DORA： AI 采用与更高交付吞吐关联，但更高的交付不稳定性仍需应对；团队流程和验证能力影响 AI
增益是否能落到最终交付。它支持在效率报告中保留质量和发布门，而不能证明本项目的具体倍数。[E1]

METR 2026-02： METR 回顾早期实验并指出，多个 AI Agent 并行时，参与者“花在任务上的时间”
能不可靠；晚 2025 工具对部分开发者呈加速趋势，但选择偏差令量化结论较弱。这直接说明本案例应独立
记录人类实际投入、Agent 并行和等待结构。[E2]

NBER 2026 修订稿： 大样本研究发现 Agent 工具带来的代码活动增幅会在项目与实际发布环节明显收敛。
其数值由特定样本与统计设计产生，不可直接换算成本项目的实施时长。对 Aegis 而言，“测试 / 验收完成
的产出”优于 commit、代码行或消息量。[E3]

9. 对照验证方案：把案例从宣传材料升级为因果证据

9.1 三组相同任务试验

- A 组： 熟练工程师 + 常规工具 / 现成框架，不使用自主编码 Agent。
- B 组： 同类工程师 + 原生 Codex Harness / 模型，但不接入 Aegis 的组织、规则和证据流程。
- C 组： 同类工程师 + Codex / 同模型 + Aegis 的组织与约束。

以同一需求冻结、可访问的代码基线、同等部署环境、独立测试门、硬件 / 生产范围和版本记录评价每组。采
用多个相近规模任务、交叉随机分配工程师 / 任务以抵消技能与题材差异；不让已看过结果的人员直接参与同
题复做。单个任务与单个用户不能排除任务难度和学习效应。

9.2 Aegis 应补采的数据

必采字段	定义 / 用途	当前状态
真实人类工时	决策、编辑、审查、环境处理、实机、返工分别计时；可重叠则归因标注
缺失
Agent 树级耗时	每节点工作开始 / 结束、阻塞 / 等待、并行峰值、关键路径	只有汇总
日志，定义待核
模型使用成本	每角色 / 模型输入输出与缓存 Token、工具 / 计算成本	缺失
质量结果	独立门通过率、严重缺陷、逃逸缺陷、30 / 90 天返工	软件阶段部分存在，

长期结果缺失 |
研发规模与复用	生产代码差异、测试代码、第三方复用量、复用起点	缺失
结果证据链	源 / 产物 hash、具体测试候选、历史 FAIL 与覆盖边界	文档中已有起点，仍需从原始记录机器提取
效果口径	同范围 WBS、系统配置、基准任务难度、独立验收冻结	尚未设计对照实验

9.3 推荐判定方法

第一阶段： 本项目标为 CASESTUDY / SOFTWARESTAGE / NOCONTROLBASELINE，33 h、400 / 600 / 900 h 情景、现有测试边界。禁止将 13.81× 作为已证因果加速或成本 ROI。第二 在 6–12 个相近工程任务上补时间、Token、缺陷追踪与独立验收；记录无 Aegis 的 B 组，计算 C−B 变化。第三阶段： 至少经历一次功能迭代和维护期，检验 Aegis 严格验证是否真的减少返工及生产缺陷。

10. 最终工程评价与可使用的表述

可使用的结论： “PROCESS V3 C/S 第一阶段，在人类主导需求与验收约束、Agent 承担大量实现与验证的协作模式下，43 小时 27 分 Agent 任务日志对应一个高可靠性约束的软件阶段交付；包含跨 Windows/Ubuntu 的真实可信连接、多层软件测试和可追溯发布证据。以 400–900 人时的同范围传统研发情景估算，名义工时量级比约 9.2–20.7 倍，中心约 13.8 倍。该数值尚未经人工 / 裸 Codex 对照校准。”

不可使用的结论： “Aegis 研发效率实测提升 14 倍或 200 倍”“相当于替代十几个开发者”“完成生产级工控验收”“所有测试均通过”“Aegis 治理本身带来 14 倍加速”。

当前优先级最高的补证： ①还原个人真实累计工时；②导出 Agent 树级时间 / Token / 成本；③用原生 Codex 与 Aegis 进行相同任务、相同质量门的 A / B 对照。完成三项后，才能把“高产出案例”推进为“可推广的增量效益证据”。

附录 A — 原始量、计算公式与复核

字段	数值	来源	限制
工作起点	2026-10-30 09:29	[U1]	截图记录，未核独立
工作截止	2026-11-05 20:40	[U1]	同上
跨度	6 d 11 h 11 min = 155.1833 h	[U1]	
完成轮次	98	[U1]	不等测试用例或人类回复数
Agent 日志时长	43 h 27 min 03 s = 43.450833 h	义才能解释并发 / 等待	
对话输入	127 条、约 6857 字符	[U2]	未计所有媒介和活动
表单 / 问题 / 图片	18 / 19 / 20	[U2]	类别可能交叠，不相
输出阅读假设	30071 字符	[U2]	全部阅读是假设，非视线追踪
人类对话时间	约 3.25 h，条件范围 2.733–4.100 h	[U2] ，不等全部人时	
传统 WBS	400 / 600 / 900 人时	[M1]	本报告的专

```text
Agent 日志小时 = 43 + 27/60 + 3/3600 = 43.4508333
自然跨度小时 = 624 + 11 + 11/60 = 155.1833333
名义量级比（中） = 600 / 43.4508333 = 13.8087
名义量级比（低 / 高） = 400/43.4508333 = 9.2058
900/43.4508333 = 20.7131
```

对话估算中心相对于 Ａｇｅｎｔ 日志 ＝ ３．２５／４３．４５０８３３３ ＝ ７．４８％
【７．４８％ 不是人机工时占比，二者定义、覆盖和重叠不同】
示例人力杠杆 ＝ ６００／１０ ＝ ６０ｘ，仅在 Ｈｔｏｔａｌ＝１０ｈ 且 Ｂ＝６００ｈ 时成立。

计算中未将测试计数当作独立用例，不对缺失数据补 ０，不以舍入后的 ４２ ｈ ３４ ｍｉｎ 重建总时间。传统 ＷＢＳ 不从 ４３ ｈ 日志反推，而是按功能块独立设定；但由于缺历史标定，这仍不构成盲评或因果对照。

附录 Ｂ — 证据登记与可追溯来源

编号	证据	本报告使用内容	可信边界
［Ｕ１］	用户提供的 Ａｅｇｉｓ 对话任务统计截图（２０２６-１１-０５）	４３：2务分类及日历跨度	统计截图；没有原始子 Ａｇｅｎｔ 时间流水
［Ｕ２］	用户提供的交流量估算截图（２０２６-１１-０５）	１２７ 消息、６８５７及 ３．２５ｈ 估算	估计输入 / 阅读，并非完整工时日志
［Ｓ１］	０１ＣＳ需求文档．ｍｄ，重点 §１、§５、§９、§１１–１７	实际阶段、边复约束、未完成项	当前整合文档；不是全部原始报告
［Ｓ２］	０２ＣＳ完整实现方案．ｍｄ，重点 §２–３、§９–２４、§３０–３１	技术际实现、计量及候选状态	作者整合的实现与历史复核说明
［Ｓ３］	０３ＣＳ历次测试项目整合．ｍｄ，重点 §１、§７–１１、§１４、§１６	C真实 Ｃ／Ｓ 测试结果和失败历史	既有证据的二级汇编，未在本报告中原始重测
［Ｍ１］	本报告 §３ 的 １１ 项 ＷＢＳ 与情景敏感性	人工 ４００／６００／9比值	分析模型，非外部事实
［Ｅ１］	ＤＯＲＡ — Ｓｔａｔｅ ｏｆ ＡＩ-ａｓｓｉｓｔｅｄ Ｓｏｆｔｗａｒｅ Ｄｅｖｅｌｏ织、吞吐与稳定性的关联性说明	不可给本项目单点基线或因果倍数
［Ｅ２］	ＭＥＴＲ — ２０２６-０２-２４ Ｕｐｌｉｆｔ Ｕｐｄａｔｅ	并行 Ａｇ偏差	与本项目系统 / 用户 / 任务不同
［Ｅ３］	ＮＢＥＲ Ｗ３５２７５（２０２６ 修订版）	编码活动增益在发布层收敛的外部不是本项目成本或速度估算数据	

外部研究使用规则： 不做跨研究乘法，不拿 ｃｏｍｍｉｔｓ 变化充当交付效率，不拿平均 ＡＩ 效应校准本项目 ＷＢＳ；所有链接仅支持方法边界与解释。报告复现只需要以上两张截图、三份用户文档、ＷＢＳ 表与计算公式，
不要求私有凭据、数据库或原始秘密材料。